

Rapport d'Évaluation — API d'Analyse de Sentiments

SocialMetrics AI — Modèle de régression logistique (scikit-learn)


Dernier entraînement : 2026-07-14 11:09:07 — 592 tweets d'entraînement, 148 tweets de validation (split 80/20)

1. Méthodologie

Le système repose sur deux régressions logistiques indépendantes entraînées sur des caractéristiques TF-IDF (unigrammes et bigrammes, accents normalisés). Le premier classifieur prédit le label **positive** et le second le label **negative** de la table MySQL tweets. Le score final retourné par l'API pour chaque tweet est la différence $P(\text{positif}) - P(\text{négatif})$, borné dans l'intervalle $[-1, 1]$: une valeur proche de 1 indique un sentiment très positif, proche de -1 un sentiment très négatif, et proche de 0 un contenu neutre. Le jeu de données est découpé en 80 % d'entraînement et 20 % de validation avec stratification, et toutes les métriques ci-dessous sont mesurées sur le jeu de validation, jamais vu pendant l'entraînement.

2. Matrices de confusion


2.1 Classe POSITIVE



Vrais négatifs : 92 — Faux positifs : 0 — Faux négatifs : 8 — Vrais positifs : 48.

Interprétation : le classifieur positif atteint une précision de 1.00 : lorsqu'il prédit qu'un tweet est positif, il ne se trompe pratiquement jamais (0 faux positif(s)). En revanche, son rappel de 0.86 montre qu'il manque 8 tweets réellement positifs, classés à tort comme non positifs. Le modèle est donc **conservateur** sur la classe positive : il préfère ne pas prédire « positif » en cas de doute, notamment pour des formulations positives implicites ou peu marquées lexicalement.

2.2 Classe NEGATIVE



Vrais négatifs : 90 — Faux positifs : 1 — Faux négatifs : 1 — Vrais positifs : 56.

Interprétation : le classifieur négatif est très équilibré, avec une précision et un rappel identiques de 0.98. Il ne commet que 1 faux positif(s) et 1 faux négatif(s) sur 148 tweets de validation. Le vocabulaire négatif (« catastrophe », « déception », « arnaque »...) est fortement discriminant, ce qui explique cette excellente séparation des classes.

3. Précision, rappel et F1-score

Classe	Accuracy	Précision	Rappel	F1-score
Positive	0.946	1.000	0.857	0.923
Négative	0.987	0.983	0.983	0.983

Lecture des métriques. La **précision** mesure la fiabilité des prédictions « classe 1 » (parmi les tweets prédits positifs/négatifs, combien le sont réellement). Le **rappel** mesure la couverture (parmi les tweets réellement positifs/négatifs, combien sont détectés). Le **F1-score** est leur moyenne harmonique et résume l'équilibre entre les deux. Pour un outil de veille d'opinion comme celui de SocialMetrics AI, un rappel élevé sur la classe négative est particulièrement important : rater des tweets négatifs signifierait passer à côté d'une crise de réputation naissante. Avec un rappel négatif de 0.98, le modèle répond bien à ce besoin.

4. Analyse des performances : forces, faiblesses, biais

Forces. Les deux classifieurs affichent des F1-scores supérieurs à 0,92, avec une détection quasi parfaite du sentiment négatif. Les scores retournés par l'API sont cohérents et gradués : un tweet enthousiaste obtient un score nettement positif, un tweet factuel (horaires, annonces) reste proche de 0, et un tweet hostile descend franchement sous 0. Le pipeline complet (MySQL → entraînement → sauvegarde joblib → API Flask) est reproductible et réentraînable automatiquement.

Faiblesses observées. L'erreur dominante est un déficit de rappel sur la classe positive : 8 tweets positifs sur 56 ne sont pas reconnus. Ces erreurs concernent typiquement des tweets positifs formulés sans mots fortement polarisés (« je reviendrai », « conforme à mes attentes ») que le TF-IDF ne relie pas assez au vocabulaire positif appris. Par ailleurs, un modèle sac-de-mots ne capture ni la **négation** (« pas mauvais du tout » risque d'être vu comme négatif), ni l'**ironie** ou le second degré, très fréquents sur X/Twitter.

Biais éventuels. (1) **Biais de domaine** : le dataset d'entraînement est construit autour d'avis de consommation (restaurants, films, applications...) ; les performances peuvent chuter sur des sujets politiques ou d'actualité. (2) **Biais lexical** : une partie du corpus est générée par gabarits, ce qui sur-représente certaines tournures et gonfle probablement les métriques par rapport à des tweets réels, plus bruités (fautes, argot, émojis, hashtags). (3) **Biais de classe** : les neutres sont sous-représentés (24 % du corpus), ce qui peut pousser le modèle à polariser des messages factuels. (4) **Biais de langue** : le modèle est monolingue français et n'a aucune garantie sur des tweets en anglais ou multilingues.

5. Recommandations d'amélioration

1. **Enrichir le dataset avec des tweets réels annotés** (via l'endpoint POST /tweets), en visant plusieurs milliers d'exemples incluant émojis, hashtags et fautes de frappe, afin de réduire le biais de génération par gabarits.

2. **Traiter la négation et les émojis** dans le prétraitement (par exemple fusionner « pas_bon » en un seul token, mapper les émojis vers des tokens de sentiment), ce qui devrait directement améliorer le rappel de la classe positive.

3. **Rééquilibrer les classes** (sur-échantillonnage des neutres ou pondération `class_weight='balanced'`) et ajuster le seuil de décision du classifieur positif pour arbitrer précision/rappel selon le besoin métier.
4. **Suivre la dérive du modèle** : conserver l'historique des métriques à chaque réentraînement hebdomadaire et déclencher une alerte si le F1-score baisse, plutôt que de remplacer le modèle aveuglément.
5. **À plus long terme**, comparer la régression logistique à des représentations plus riches (embeddings type fastText ou CamemBERT) qui capturent le contexte et l'ironie, tout en gardant la régression logistique comme référence simple et interprétable.